




LAPORAN TUGAS BESAR BIG DATA

Analisis Sentimen Pelanggan

Meningkatkan Kualitas Layanan dan Kepuasan
Pelanggan

TUGAS BESAR BIG DATA



Daftar Kelompok



01

Muhammad Ilyas Alyasa (1301213121)

02

Dinda Cantika Putri Baruara (103012300135)

03

Bianka Rosa (103012300335)

04

Adam Teguh Maulaanaa (1301213218)

Pendahuluan

Mengapa Sentimen Pelanggan Penting?

Perkembangan platform perdagangan elektronik telah mendorong lonjakan volume ulasan produk secara digital. Amazon, sebagai salah satu platform niaga daring terbesar di dunia, menampung jutaan ulasan dari pelanggan setiap harinya, termasuk pada kategori produk buku digital (digital ebook). Ulasan tersebut memuat informasi berharga berupa penilaian bintang dan teks opini yang mencerminkan kepuasan maupun ketidakpuasan pelanggan terhadap produk yang dibeli.



Rumusan Masalah



Bagaimana membangun pipeline pemrosesan data berskala besar ?



Bagaimana membangun model klasifikasi sentimen berbasis NLP



Bagaimana menganalisis pola perilaku pelanggan berdasarkan hasil prediksi sentimen ?

Tujuan Proyek

- 01** Membangun pipeline pembersihan dan praproses data ulasan Amazon Ebook
- 02** Melatih dan mengevaluasi model klasifikasi sentimen dengan pendekatan NLP berbasis TF-IDF dan Regresi Logistik
- 03** Menganalisis perilaku pelanggan melalui visualisasi data berdasarkan empat dimensi: pola sentimen pada pembelian terverifikasi

Manfaat Proyek



Proyek ini diharapkan dapat menghasilkan model klasifikasi sentimen ulasan pelanggan yang akurat dan efisien menggunakan teknologi Apache Spark, serta memberikan pemahaman mengenai penerapan AI dan Big Data dalam analisis teks berskala besar. Hasil proyek ini juga dapat menjadi referensi awal bagi pengembangan sistem analisis sentimen berbasis machine learning pada lingkungan pemrosesan data yang lebih kompleks dan realistis.



Penggunaan Dataset



Dataset yang digunakan dalam proyek ini adalah Amazon US Customer Reviews Dataset kategori Digital Ebook Purchase

Deskripsi Atribut Dataset

01

review_body : Teks ulasan yang ditulis oleh pelanggan, digunakan sebagai masukan utama model NLP.

02

star_rating : penilaian bintang dalam skala 1 hingga 5 diberikan pelanggan terhadap produk.

03

verified_purchase : status yang menunjukkan apakah ulasan berasal dari pelanggan yang benar-benar melakukan pembelian

04

helpful_votes : jumlah suara dari pelanggan lain yang menilai ulasan tersebut bermanfaat.



HASIL ANALISIS DAN VISUALISASI

01

Area Under ROC
(AUC) : 0.9462



02

Akurasi : 91.88%



03

F1-Score : 0.8984




04

Weighted
Precision : 0.9168


05

Weighted Recall :
0.9188




HASIL ANALISIS DAN VISUALISASI

Sentimen Berdasarkan Status Verifikasi



Berdasarkan grafik tersebut, pelanggan dengan status pembelian terverifikasi (Y) mendominasi seluruh distribusi ulasan, dengan jumlah ulasan bersentimen positif (label 1) mencapai sekitar 680.000 ulasan, jauh lebih tinggi dibandingkan ulasan negatif (label 0) yang hanya sekitar 15.000 ulasan. Pada kelompok tidak terverifikasi (N), ulasan positif tetap mendominasi dengan sekitar 210.000 ulasan, namun proporsi ulasan negatif relatif lebih tinggi dibandingkan kelompok terverifikasi





HASIL ANALISIS DAN VISUALISASI

Sentimen dan Helpful Votes



Berdasarkan grafik tersebut, ulasan bersentimen negatif (label 0) memiliki rata-rata helpful votes sekitar 7,2, jauh lebih tinggi dibandingkan ulasan bersentimen positif (label 1) yang hanya sekitar 1,4. Hal ini mengindikasikan bahwa pelanggan lain cenderung menganggap ulasan negatif lebih bermanfaat dibandingkan ulasan positif.







HASIL ANALISIS DAN VISUALISASI

Panjang Ulasan dan Sentimen

- ✓ Berdasarkan grafik tersebut, ulasan bersentimen negatif (label 0) memiliki rata-rata panjang teks sekitar 1.000 karakter, lebih dari dua kali lipat dibandingkan ulasan bersentimen positif (label 1) yang hanya sekitar 450 karakter.






HASIL ANALISIS DAN VISUALISASI

Distribusi Rating



Berdasarkan grafik tersebut, distribusi rating bintang menunjukkan ketidakseimbangan kelas yang sangat signifikan. Rating bintang 5 mendominasi dengan jumlah sekitar 3.000.000 ulasan, diikuti rating 4 sekitar 1.200.000 ulasan, rating 3 sekitar 500.000 ulasan, serta rating 1 dan 2 yang masing-masing hanya sekitar 250.000 ulasan. Secara keseluruhan.



Kesimpulan



Proyek ini berhasil membangun sistem analisis sentimen ulasan pelanggan produk buku digital Amazon menggunakan Apache Spark dan machine learning berbasis NLP. Dataset berukuran 3,22 GB dapat diproses secara efisien, sementara model Regresi Logistik dengan TF-IDF menunjukkan kinerja baik dengan AUC 0,9462 dan akurasi 91,88%. Hasil analisis juga menunjukkan adanya perbedaan pola sentimen berdasarkan status pembelian, helpful votes, panjang ulasan, serta distribusi rating. Secara keseluruhan, proyek ini membuktikan bahwa integrasi Big Data dan kecerdasan buatan efektif untuk menganalisis ulasan pelanggan berskala besar.