

LAPORAN TUGAS BESAR BIG DATA

Studi Kasus: Analisis Sentimen Pelanggan



**Universitas
Telkom**

Disusun oleh:

Muhammad Ilyas Alyasa (1301213121)

Dinda Cantika Putri Baruara (103012300135)

Bianka Rosa (103012300335)

Adam Teguh Maulaanaa (1301213218)

PROGRAM STUDI S1 INFORMATIKA

FAKULTAS INFORMATIKA

UNIVERSITAS TELKOM

BANDUNG

2026

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perkembangan platform perdagangan elektronik telah mendorong lonjakan volume ulasan produk secara digital. Amazon, sebagai salah satu platform niaga daring terbesar di dunia, menampung jutaan ulasan dari pelanggan setiap harinya, termasuk pada kategori produk buku digital (*digital ebook*). Ulasan tersebut memuat informasi berharga berupa penilaian bintang dan teks opini yang mencerminkan kepuasan maupun ketidakpuasan pelanggan terhadap produk yang dibeli.

Namun, volume data yang sangat besar menjadi tantangan tersendiri dalam proses analisis. Pendekatan konvensional tidak lagi memadai untuk memproses data berskala jutaan rekaman secara efisien. Oleh karena itu, diperlukan teknologi pemrosesan data besar (*big data*) yang mampu menangani beban komputasi tinggi. Apache Spark menjadi salah satu solusi yang relevan karena mendukung pemrosesan terdistribusi secara paralel dan memiliki ekosistem *machine learning* yang terintegrasi melalui pustaka MLlib.

Di sisi lain, analisis sentimen berbasis teks ulasan merupakan pendekatan yang efektif untuk memahami perilaku pelanggan secara otomatis. Dengan menerapkan teknik *Natural Language Processing* (NLP) dan model klasifikasi seperti Regresi Logistik, sentimen pelanggan dapat diprediksi secara terprogram tanpa perlu menelaah setiap ulasan secara manual. Pendekatan ini membuka peluang untuk mengekstrak wawasan perilaku pelanggan secara luas dan terukur.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam proyek ini adalah sebagai berikut.

1. Bagaimana membangun *pipeline* pemrosesan data berskala besar dari dataset ulasan Amazon Ebook menggunakan Apache Spark?

2. Bagaimana membangun model klasifikasi sentimen berbasis NLP untuk memprediksi sentimen ulasan pelanggan secara otomatis?
3. Bagaimana menganalisis pola perilaku pelanggan berdasarkan hasil prediksi sentimen, ditinjau dari status verifikasi pembelian, jumlah suara membantu (*helpful votes*), panjang teks ulasan, dan distribusi rating bintang?

1.3 Tujuan Proyek

Tujuan yang ingin dicapai dalam proyek ini adalah sebagai berikut.

1. Membangun *pipeline* pembersihan dan praproses data ulasan Amazon Ebook berskala besar menggunakan Apache Spark.
2. Melatih dan mengevaluasi model klasifikasi sentimen dengan pendekatan NLP berbasis TF-IDF dan Regresi Logistik.
3. Menganalisis perilaku pelanggan melalui visualisasi data berdasarkan empat dimensi: pola sentimen pada pembelian terverifikasi, dampak sentimen terhadap *helpful votes*, korelasi panjang ulasan dengan sentimen, serta distribusi rating bintang keseluruhan.

1.4 Manfaat Proyek

Proyek ini diharapkan dapat menghasilkan model klasifikasi sentimen ulasan pelanggan yang akurat dan efisien menggunakan teknologi Apache Spark, serta memberikan pemahaman mengenai penerapan AI dan Big Data dalam analisis teks berskala besar. Hasil proyek ini juga dapat menjadi referensi awal bagi pengembangan sistem analisis sentimen berbasis *machine learning* pada lingkungan pemrosesan data yang lebih kompleks dan realistis.

BAB 2

DESKRIPSI DATASET DAN STUDI KASUS

2.1 Dataset

Dataset yang digunakan dalam proyek ini adalah Amazon US Customer Reviews Dataset kategori Digital Ebook Purchase, yang bersumber dari platform Kaggle dengan nama berkas `amazon_reviews_us_Digital_Ebook_Purchase_v1_01.tsv`. Dataset berukuran 3,22 GB dalam format TSV (Tab-Separated Values) dan memuat atribut utama berupa `review_body`, `star_rating`, `verified_purchase`, dan `helpful_votes` yang menjadi dasar seluruh proses analisis.

2.2 Deskripsi Atribut Dataset

Dataset memuat sejumlah atribut yang merekam informasi ulasan pelanggan secara lengkap. Atribut yang digunakan dalam proyek ini adalah sebagai berikut.

Atribut	Keterangan
<code>review_body</code>	teks ulasan yang ditulis oleh pelanggan, digunakan sebagai masukan utama model NLP.
<code>star_rating</code>	penilaian bintang dalam skala 1 hingga 5 yang diberikan pelanggan terhadap produk.
<code>verified_purchase</code>	status yang menunjukkan apakah ulasan berasal dari pelanggan yang benar-benar melakukan pembelian.
<code>helpful_votes</code>	jumlah suara dari pelanggan lain yang menilai ulasan tersebut bermanfaat.

2.3 Studi Kasus

Studi kasus dalam proyek ini berfokus pada analisis sentimen ulasan pelanggan terhadap produk buku digital di platform Amazon. Permasalahan utama yang dikaji adalah kemampuan model dalam mengklasifikasikan sentimen ulasan secara otomatis berdasarkan teks yang ditulis pelanggan, tanpa bergantung pada nilai rating bintang secara langsung.

Selain klasifikasi sentimen, proyek ini juga mengkaji pola perilaku pelanggan melalui empat dimensi analisis, yaitu hubungan antara status verifikasi pembelian dengan kecenderungan sentimen, pengaruh sentimen terhadap tingkat *helpful votes*, korelasi antara panjang teks ulasan dengan sentimen yang diekspresikan, serta distribusi rating bintang secara keseluruhan dalam dataset.

2.4 Relevansi Dataset terhadap Pendekatan Big Data dan AI

Dataset ini dipilih karena volumenya yang besar (3,22 GB) sehingga tidak dapat diproses secara efisien menggunakan pendekatan komputasi konvensional. Karakteristik tersebut menjadikan dataset ini relevan sebagai bahan studi dalam konteks mata kuliah Big Data dan Kecerdasan Buatan, khususnya untuk mendemonstrasikan pemrosesan data terdistribusi menggunakan Apache Spark serta penerapan model *machine learning* berbasis NLP pada data teks berskala besar.

BAB 3

METODOLOGI

3.1 Alur Penelitian

Penelitian ini dilaksanakan melalui serangkaian tahapan yang terstruktur dan berurutan. Tahap pertama adalah akuisisi dataset dari platform Kaggle menggunakan Kaggle API, kemudian data dimuat ke dalam lingkungan Apache Spark. Tahap kedua adalah praproses dan pembersihan data guna memastikan kualitas data yang akan digunakan dalam pelatihan model. Tahap ketiga adalah rekayasa fitur (*feature engineering*) berbasis NLP untuk mengubah teks ulasan menjadi representasi numerik. Tahap keempat adalah pelatihan model klasifikasi menggunakan algoritma Regresi Logistik. Tahap kelima adalah evaluasi kinerja model menggunakan beberapa metrik kuantitatif. Tahap terakhir adalah analisis perilaku pelanggan berbasis hasil prediksi sentimen yang divisualisasikan dalam bentuk grafik.

3.2 Tahapan Pre-proses Data

Praproses data merupakan tahapan krusial sebelum model dapat dilatih. Seluruh proses dilakukan di atas Apache Spark menggunakan PySpark agar mampu menangani volume data yang besar secara efisien.

3.2.1 Seleksi dan Pembersihan Fitur

Dataset mentah dimuat ke dalam Spark DataFrame menggunakan `spark.read.csv` dengan parameter `header=True`, `sep='\t'`, dan `inferSchema=True`. Setelah data berhasil dimuat, dilakukan pembersihan dengan menghapus seluruh baris yang memiliki nilai kosong pada kolom `review_body`, `star_rating`, `verified_purchase`, dan `helpful_votes` menggunakan metode `dropna`. Selanjutnya, tipe data kolom `star_rating` dan `helpful_votes` dikonversi secara eksplisit ke tipe integer menggunakan `cast(IntegerType())` guna memastikan konsistensi tipe data sebelum masuk ke tahap berikutnya.

3.2.2 Label Encoding

Ulasan dengan rating bintang bernilai 3 dieliminasi terlebih dahulu karena bersifat netral dan tidak dapat dikategorikan secara tegas sebagai positif maupun negatif. Setelah itu, setiap ulasan

diberi label sentimen secara otomatis menggunakan fungsi `when`: rating 4 dan 5 diberi label 1 (positif), sedangkan rating 1 dan 2 diberi label 0 (negatif). Hasil pelabelan disimpan dalam DataFrame `df_labeled` yang menjadi dasar seluruh proses pelatihan model.

3.2.3 Feature Engineering

Rekayasa fitur dilakukan melalui empat tahapan NLP yang dirangkai secara berurutan dalam PySpark MLlib. Pertama, teks pada kolom `review_body` dipecah menjadi kumpulan token kata menggunakan `Tokenizer`. Kedua, kata-kata umum yang tidak memiliki nilai diskriminatif dihilangkan menggunakan `StopWordsRemover`. Ketiga, frekuensi kemunculan setiap kata direpresentasikan dalam bentuk vektor numerik menggunakan `HashingTF` dengan jumlah fitur sebesar 10.000. Keempat, bobot tiap kata dinormalisasi berdasarkan tingkat kepentingannya dalam keseluruhan korpus menggunakan `IDF`, sehingga kata yang terlalu umum memperoleh bobot lebih rendah dibandingkan kata yang lebih spesifik dan informatif.

3.2.4 Train-Test Split

Dataset yang telah melalui seluruh tahapan praproses dan pelabelan dibagi menjadi dua bagian menggunakan metode `randomSplit`. Sebesar 80% data digunakan sebagai data latih (training set) dan 20% sisanya digunakan sebagai data uji (testing set), dengan nilai `seed=42` untuk memastikan hasil pembagian yang konsisten dan dapat direproduksi.

3.3 Algoritma AI yang Digunakan

Algoritma kecerdasan buatan yang digunakan dalam proyek ini adalah Regresi Logistik (Logistic Regression) yang diimplementasikan melalui kelas `LogisticRegression` pada pustaka PySpark MLlib. Regresi Logistik dipilih karena sesuai untuk tugas klasifikasi biner dan mampu bekerja secara efisien pada data berdimensi tinggi yang dihasilkan dari proses ekstraksi fitur TF-IDF. Model dikonfigurasi dengan dua parameter utama, yaitu `maxIter=10` yang membatasi jumlah maksimum iterasi selama proses optimasi, dan `regParam=0.1` sebagai nilai regularisasi L2 guna mencegah overfitting pada data latih.

Seluruh komponen, mulai dari tahapan NLP hingga model klasifikasi, dirangkai dalam satu objek Pipeline milik PySpark MLlib dengan urutan stages sebagai berikut: `Tokenizer` →

StopWordsRemover → HashingTF → IDF → LogisticRegression. Pendekatan pipeline ini memastikan bahwa setiap data yang masuk, baik data latih maupun data uji, melewati transformasi yang identik secara otomatis tanpa risiko kebocoran data (data leakage). Pelatihan model dilakukan dengan memanggil `pipeline.fit(train_data)` pada data latih, dan prediksi dihasilkan melalui `model.transform(test_data)` pada data uji.

3.4 Integrasi dengan Apache Spark

Apache Spark digunakan sebagai kerangka utama pemrosesan data terdistribusi dalam proyek ini melalui pustaka PySpark. Sesi Spark diinisialisasi menggunakan `SparkSession.builder` dengan nama aplikasi `AmazonEbookBigDataAI` dan konfigurasi alokasi memori driver sebesar 8 GB serta memori executor sebesar 4 GB, guna menangani volume data yang mencapai 3,22 GB secara stabil dan efisien.

Integrasi Spark mencakup seluruh alur kerja proyek, mulai dari pemuatan data TSV menggunakan `spark.read.csv`, praproses menggunakan fungsi bawaan `pyspark.sql.functions`, rekayasa fitur dan pelatihan model menggunakan `pyspark.ml`, hingga agregasi hasil prediksi untuk keperluan analisis perilaku pelanggan. Seluruh operasi tersebut dieksekusi di atas Spark `DataFrame` yang bersifat *lazy evaluation*, artinya komputasi hanya dijalankan saat hasil benar-benar dibutuhkan, sehingga penggunaan sumber daya menjadi lebih efisien.

Pada tahap analisis perilaku pelanggan, mekanisme *caching* diterapkan pada `DataFrame predictions` menggunakan `predictions.cache()` untuk menghindari komputasi ulang saat `DataFrame` yang sama digunakan dalam beberapa operasi agregasi secara berurutan. Setelah seluruh agregasi selesai, *cache* dibebaskan menggunakan `predictions.unpersist()` guna mengoptimalkan penggunaan memori.

3.5 Metrik Evaluasi

Kinerja model dievaluasi menggunakan lima metrik kuantitatif yang diterapkan pada data uji sebesar 20% dari keseluruhan dataset. Evaluasi dilakukan menggunakan dua kelas evaluator dari PySpark `MLlib`, yaitu `BinaryClassificationEvaluator` untuk metrik AUC dan `MulticlassClassificationEvaluator` untuk keempat metrik lainnya. Adapun metrik yang digunakan disajikan pada tabel berikut.

Metrik	Keterangan
<i>Area Under ROC</i> (AUC)	Mengukur kemampuan model dalam membedakan kelas positif dan negatif secara keseluruhan. Nilai mendekati 1,0 menunjukkan kinerja yang sangat baik.
Akurasi	Menghitung proporsi prediksi benar terhadap seluruh data uji.
F1-Score	Rata-rata harmonik antara <i>precision</i> dan <i>recall</i> , memberikan gambaran kinerja yang lebih seimbang apabila terdapat ketidakseimbangan jumlah antar kelas.
<i>Weighted Precision</i>	Mengukur tingkat ketepatan prediksi dengan mempertimbangkan proporsi tiap kelas.
<i>Weighted Recall</i>	Mengukur kemampuan model dalam mendeteksi seluruh sampel dari masing-masing kelas secara proporsional.

BAB 4

HASIL ANALISIS DAN VISUALISASI

4.1 Hasil Pelatihan Model

Pelatihan model dilakukan menggunakan pipeline PySpark MLlib yang telah dirangkai pada tahap sebelumnya. Data latih sebesar 80% dari keseluruhan dataset digunakan sebagai masukan fungsi `pipeline.fit(train_data)`. Seluruh tahapan transformasi NLP, mulai dari tokenisasi, penghapusan stopwords, ekstraksi fitur TF-IDF, hingga pelatihan model Regresi Logistik, dieksekusi secara otomatis dan terdistribusi di atas infrastruktur Apache Spark. Model berhasil dilatih tanpa kendala dan siap digunakan untuk menghasilkan prediksi pada data uji.

4.2 Hasil Evaluasi Model

Evaluasi model dilakukan terhadap data uji sebesar 20% dari keseluruhan dataset menggunakan lima metrik yang telah ditetapkan. Hasil evaluasi disajikan pada tabel berikut.

Metrik	Hasil
<i>Area Under ROC (AUC)</i>	0.9462
Akurasi	91.88%
F1-Score	0.8984
<i>Weighted Precision</i>	0.9168
<i>Weighted Recall</i>	0.9188


Berdasarkan hasil evaluasi di atas, model Regresi Logistik yang dibangun di atas *pipeline* NLP berbasis TF-IDF menunjukkan kinerja yang baik dalam mengklasifikasikan sentimen ulasan pelanggan. Nilai AUC sebesar 0,9462 mengindikasikan bahwa model memiliki kemampuan yang tinggi dalam membedakan kelas positif dan negatif. Akurasi sebesar 91,88% menunjukkan bahwa sebagian besar prediksi model sesuai dengan label aktual pada data uji. F1-Score sebesar 0,8984 mengonfirmasi bahwa keseimbangan antara *precision* dan *recall* terjaga dengan baik, sehingga model tidak hanya akurat secara keseluruhan tetapi juga andal dalam mendeteksi kedua kelas sentimen secara proporsional.

4.3 Analisis Perilaku Pelanggan

Analisis perilaku pelanggan dilakukan berdasarkan hasil prediksi sentimen model terhadap data uji. Terdapat empat dimensi analisis yang divisualisasikan menggunakan Matplotlib dan Seaborn.

4.3.1 Pola Sentimen Berdasarkan Status Verifikasi Pembelian


Analisis pertama membandingkan distribusi sentimen antara pelanggan dengan status pembelian terverifikasi (Y) dan tidak terverifikasi (N). Visualisasi disajikan dalam bentuk diagram batang berkelompok yang memisahkan jumlah ulasan bersentimen positif (label 1) dan negatif (label 0) pada masing-masing kelompok.



Berdasarkan grafik tersebut, pelanggan dengan status pembelian terverifikasi (Y) mendominasi seluruh distribusi ulasan, dengan jumlah ulasan bersentimen positif (label 1) mencapai sekitar 680.000 ulasan, jauh lebih tinggi dibandingkan ulasan negatif (label 0) yang hanya sekitar 15.000 ulasan. Pada kelompok tidak terverifikasi (N), ulasan positif tetap mendominasi dengan sekitar 210.000 ulasan, namun proporsi ulasan negatif relatif lebih tinggi dibandingkan kelompok terverifikasi. Hal ini mengindikasikan bahwa pelanggan yang telah melakukan pembelian secara terverifikasi cenderung memberikan ulasan yang lebih positif, sementara pelanggan tidak terverifikasi memiliki kecenderungan sentimen negatif yang lebih besar secara proporsional.

4.3.2 Dampak Sentimen terhadap Helpful Votes


Analisis kedua mengkaji hubungan antara sentimen ulasan dengan rata-rata jumlah helpful votes yang diperoleh. Agregasi dilakukan dengan menghitung nilai rata-rata kolom `helpful_votes` untuk masing-masing kelas sentimen menggunakan fungsi `avg` pada PySpark.



Berdasarkan grafik tersebut, ulasan bersentimen negatif (label 0) memiliki rata-rata *helpful votes* sekitar 7,2, jauh lebih tinggi dibandingkan ulasan bersentimen positif (label 1) yang hanya sekitar 1,4. Hal ini mengindikasikan bahwa pelanggan lain cenderung menganggap ulasan negatif lebih bermanfaat dibandingkan ulasan positif. Kemungkinan besar karena ulasan negatif memuat informasi yang lebih spesifik, kritis, dan detail mengenai kekurangan produk, sehingga lebih membantu calon pembeli dalam pengambilan keputusan.

4.3.3 Korelasi Panjang Teks Ulasan dengan Sentimen


Analisis ketiga mengukur rata-rata panjang teks ulasan berdasarkan kelas sentimen. Panjang teks dihitung menggunakan fungsi `length` pada kolom `review_body`, kemudian diagregasi per kelas sentimen untuk memperoleh nilai rata-rata jumlah karakter.



Berdasarkan grafik tersebut, ulasan bersentimen negatif (label 0) memiliki rata-rata panjang teks sekitar 1.000 karakter, lebih dari dua kali lipat dibandingkan ulasan bersentimen positif (label 1) yang hanya sekitar 450 karakter. Hal ini mengonfirmasi bahwa pelanggan yang merasa tidak puas cenderung menuliskan ulasan yang jauh lebih panjang dan detail. Kecenderungan tersebut dapat dijelaskan oleh motivasi pelanggan yang kecewa untuk menguraikan keluhan secara spesifik, sedangkan pelanggan yang puas cenderung menyampaikan apresiasi secara singkat.

4.3.4 Distribusi Rating Bintang Keseluruhan

Analisis keempat menampilkan distribusi rating bintang asli (1–5) dari seluruh data yang telah melalui proses pembersihan, termasuk ulasan dengan rating bintang 3 yang sebelumnya dieliminasi dari proses pelatihan model. Data agregasi diambil dari DataFrame `df_clean` menggunakan `groupBy("star_rating").count()`.



Berdasarkan grafik tersebut, distribusi rating bintang menunjukkan ketidakseimbangan kelas yang sangat signifikan. Rating bintang 5 mendominasi dengan jumlah sekitar 3.000.000 ulasan, diikuti rating 4 sekitar 1.200.000 ulasan, rating 3 sekitar 500.000 ulasan, serta rating 1 dan 2 yang masing-masing hanya sekitar 250.000 ulasan. Secara keseluruhan, lebih dari 80% pelanggan memberikan penilaian positif (rating 4 dan 5), yang mengonfirmasi bahwa dataset ini bersifat tidak seimbang (*imbalanced*) dengan dominasi kelas positif yang sangat kuat. Kondisi ini relevan untuk diperhatikan dalam interpretasi kinerja model, karena model yang dilatih pada data tidak seimbang cenderung lebih baik dalam memprediksi kelas mayoritas.

BAB 5

KESIMPULAN

Proyek ini berhasil membangun sistem analisis sentimen ulasan pelanggan terhadap produk buku digital Amazon menggunakan pendekatan *Big Data* dan kecerdasan buatan. Pemrosesan dataset berukuran 3,22 GB dilakukan secara efisien menggunakan Apache Spark dengan konfigurasi memori yang dioptimalkan, membuktikan bahwa teknologi pemrosesan terdistribusi mampu menangani volume data yang tidak dapat diproses secara konvensional.

Model klasifikasi Regresi Logistik yang dibangun di atas *pipeline* NLP berbasis TF-IDF menghasilkan kinerja yang baik, ditunjukkan oleh nilai AUC sebesar 0,9462, akurasi 91,88%, F1-Score 0,8984, *Weighted Precision* 0,9168, dan *Weighted Recall* 0,9188. Hasil tersebut mengonfirmasi bahwa representasi fitur teks menggunakan kombinasi HashingTF dan IDF cukup efektif untuk membedakan sentimen positif dan negatif pada data ulasan berskala besar.

Analisis perilaku pelanggan yang dilakukan terhadap hasil prediksi model menghasilkan empat temuan. Pertama, pelanggan dengan status pembelian terverifikasi menunjukkan pola sentimen yang berbeda dibandingkan pelanggan tidak terverifikasi. Kedua, terdapat perbedaan rata-rata *helpful votes* antara ulasan bersentimen positif dan negatif. Ketiga, panjang teks ulasan berkorelasi dengan kelas sentimen yang diekspresikan pelanggan. Keempat, distribusi rating bintang pada dataset menunjukkan ketidakseimbangan kelas yang dominan pada rating tertentu.

Secara keseluruhan, proyek ini membuktikan bahwa integrasi Apache Spark dan *machine learning* berbasis NLP merupakan pendekatan yang layak dan efektif untuk menganalisis data ulasan pelanggan berskala besar, serta memberikan pemahaman praktis mengenai penerapan konsep *Big Data* dan kecerdasan buatan dalam konteks nyata.